

Forecasting de Series Temporales en Ocho Dominios Industriales

La asimetría de palancas: 44 % máximo por modelo vs. 2 900 % por régimen de datos

▲ Magnitudes de naturaleza distinta — ver Anexo de incomparabilidad, diapositiva 28

*Presentación de la monografía aplicada sobre `course-timeseries-benchmarks-pro`
Autor pendiente de confirmación · Fecha de defensa pendiente de confirmación*

*Nivel de análisis: socio-técnico / operacional. Las series modeladas son fenómenos organizacionales; no se afirma causalidad física ni biológica.
Audiencia primaria: profesionales de industria (ML engineers, planificación, supply chain) que toman decisiones operativas con datos reales.*

Ocho dominios, una ruta de complejidad

- **Capítulos 2–9:** un experimento por dominio sobre datos reales, del baseline ingenuo al forecasting probabilístico
- **Capítulo 10:** síntesis por palancas, jerarquía de impacto, TCO y recomendación operativa
- **Cierre:** deudas administradas (especificado vs. ejecutado) y anexos de defensa

Cuatro rutas de lectura, según tu rol

- **Si eres ML Engineer:** Capítulos 2–9 (método + decisión ejecutiva de cada slide «Resultados»/«Método y lección»)
- **Si eres Stakeholder / Decisor:** Jerarquía de palancas + TCO + Cuatro acciones + Anexos
- **Si evalúas rigor metodológico:** Honestidad (especificado vs. ejecutado) + Anexos de asteriscos
- **Regla de lectura:** los números-tótem con asterisco (*) llevan una condición de validez explícita — compárense palancas entre capítulos, no métricas

NOTA

Repositorio: `course-timeseries-benchmarks-pro` v1.1.0 · integridad verificable con `MANIFEST.sha256` (SHA-256 por archivo) · `SEED = 42` en los ocho notebooks · entorno acotado en `requirements.txt`.

Ocho experimentos reales, una pregunta transversal

8 datasets · 8 notebooks ejecutados

Sin resultados simulados, sin covariables inventadas

- **6 principios:** reproducibilidad, autocontenido, transparencia, realismo, progresión, gobierno
- **Ruta de modelado:** naive → ARIMA → SARIMAX → ML tabular → global → LSTM → arquitecturas modernas → probabilístico
- **3 preguntas de investigación** organizan los ocho capítulos técnicos + la síntesis del Cap. 10: ¿cuándo paga la complejidad?, ¿qué papel cumplen las exógenas?, ¿qué hacer con residuos no gaussianos?

DECISIÓN EJECUTIVA

Ocho experimentos, un protagonista recurrente (LightGBM, cuatro encarnaciones) y una tesis: dónde se invierte la complejidad importa más que cuánta.

Taxonomía de los ocho datasets

Sem.	Dataset	Frecuencia	Desafío principal
1	Metro Traffic	Horaria	Duplicados y gaps en timestamps
2	Appliances Energy	10 min	Exceso de covariables, target ruidoso
3	Beijing PM2.5	Horaria	Nulos interiores; exógenas oracle
4	Bike Sharing	Horaria	Fuga directa (<code>cnt = casual + registered</code>)
5	Electricity	Horaria	Escala: 9.7M filas; cold-start
6	OPSD Germany	Horaria	43 columnas, cobertura desigual
7	PeMS-SF	10 min	Sin fechas calendario; 963 sensores
8	M3 Monthly	Mensual	1,428 series cortas (66–144 obs.)

El baseline estacional gana: MASE 0.916

MASE 0.916

SeasonalNaive168 — nadie lo supera en este capítulo

DOMINIO: Tráfico vehicular	DECISIÓN: Turnos · carriles	HORIZONTE: 8,115 h (≈ 11 meses)
BASELINE: SeasonalNaive168	RIESGO: Random split inválido	MÉTRICA: MASE

Modelo	MASE	WAPE (%)
SeasonalNaive168	0.916	11.05
ETS	1.967	23.73
Naive	7.770	93.71

El random split es inválido: filtra el futuro

- Split temporal 80/20: 8,115 h de test (11 meses); el aleatorio «espía» el futuro y subestima el error (MAE 251.66 vs. 287.55)
- Residuos del baseline: Ljung-Box, Jarque-Bera y ARCH LM rechazan independencia, normalidad y homocedasticidad
- El diagnóstico guía: estacionalidad semanal fuerte → el baseline estacional es difícil de superar

DECISIÓN EJECUTIVA

En series temporales validar siempre con división temporal; el random split no estima el error de producción.

ARIMA sigue el protocolo correcto y aun así pierde

MASE 0.681

ETS gana; ARIMA(1,0,2), elegido por AIC, queda último

DOMINIO: Energía residencial	DECISIÓN: Detectar picos	HORIZONTE: 24 h
BASELINE: ETS · Theta · SN24	RIESGO: Elegir solo por AIC/BIC	MÉTRICA: MASE


Modelo	MASE (test)
ETS	0.681
Theta	0.748
SeasonalNaive24	0.834
ARIMA(1,0,2)	0.901

La validación temporal decide, no el AIC

- Grid de 18 órdenes: AIC en train, MAE en validación, test consultado una sola vez
- El orden ganador por AIC (1,0,2) pierde contra ETS, Theta y SN24 en test
- Residuos: la estructura reaparece en lags ≥ 20 (ciclo diario); error $3\times$ mayor en picos (572 vs. 163)

DECISIÓN EJECUTIVA

No elegir un modelo solo por AIC/BIC; comprobar residuos y validar temporalmente.



Esquema conceptual — no son datos reales

Las exógenas mejoran 18.36% — bajo un escenario oracle

-18.36% de MAE

SARIMAX vs. SARIMA, promedio de 3 folds rolling-origin

DOMINIO: Calidad del aire	DECISIÓN: Alertas · restricciones	HORIZONTE: 168 h
BASELINE: SARIMA sin exógenas	RIESGO: Oracle: clima observado	MÉTRICA: MAE

Modelo	MAE medio	Desv. entre folds
SARIMA	103.66	10.58
SARIMAX	84.99	14.13

Exógenas: promesa con tres condiciones

- **Discrepancia README (20.7 %) vs. notebook recalculado (18.36 %):** evidencia de ejecución real — el README redondea o usa media aritmética; el notebook recalcula por fold con la fórmula oficial del Cap. 4
- Rolling-origin de 3 folds: train 180 días, test 168 h, orígenes separados 30 días
- Imputación causal `ffill` (límite 24 h) + mediana de train, recalculada por fold; SARIMAX es menos estable (desv. 14.13 vs. 10.58)

DECISIÓN EJECUTIVA

Usar una exógena solo si mejora la validación, es estable entre folds y estará disponible en producción.

-44 % con feature store auditado: la victoria es del protocolo

-44% de MASE

LightGBM/RandomForest vs. modelos lineales

DOMINIO: Micromovilidad	DECISIÓN: Rebalanceo de flota	HORIZONTE: Horaria
BASELINE: Lineales con features	RIESGO: Leakage	MÉTRICA: MASE


Modelo	MASE
LightGBM	0.457
RandomForest	0.471
Ridge / Linear	0.818

El leakage se cuantifica, no se asume

- `cnt` = `casual` + `registered` excluido: fuga directa del target
- Walk-forward de 3 folds expansivos + embargo 24 h; escalador ajustado solo con train
- 37 features finales: lags, ventanas 24/48/168 h, codificación cíclica e interacciones

DECISIÓN EJECUTIVA

El ML tabular gana cuando el feature engineering es riguroso y la validación es temporal.



Esquema conceptual — no son datos reales

Sin historia del cliente, ningún modelo recupera la escala

29× de diferencia

MASE mediano: warm-start 1.34 vs. cold-start 38.59

DOMINIO: Energía · 370 clientes	DECISIÓN: Ofertas a clientes nuevos	HORIZONTE: 168 h
BASELINE: Perfil hora×día	RIESGO: Confiar en el modelo global	MÉTRICA: MASE macro

Modelo	MAE	MASE macro
Perfil hora×día	3,178.72	69.44
LightGBM global	3,178.39	69.44


- Empate técnico (−0.01 %). **Dos estadísticos:** 29× usa medianas (1.34 vs. 38.59); 69.44 es MASE **macro** (media, castigada por la cola).

Global no es automáticamente mejor

- Cold-start estricto: 296 clientes entrenan, 74 nunca vistos (solo features de calendario)
- Heterogeneidad de escala: 4.36 a 190,542 (razón 43,000×); clústeres $k=4$ (213/119/34/4)
- El modelo global transfiere la forma del patrón, no la escala individual

DECISIÓN EJECUTIVA

Sin historia: perfil hora×día. Con historia: el modelo no importa tanto como creía.



Esquema conceptual — no son datos reales

El asterisco del 0.234: atribución abierta

MASE 0.234

LightGBM; la LSTM (0.576) pierde hasta contra el naive (0.495)

DOMINIO: Energía nacional	DECISIÓN: Despacho · capacidad	HORIZONTE: 168 h
BASELINE: SeasonalNaive	RIESGO: Elegir LSTM por moda	MÉTRICA: MASE

Modelo	MASE
LightGBM	0.234
SeasonalNaive	0.495
LSTM	0.576
ARIMA(2,1,2)	3.263

(*) 0.234 incluye DE_load_forecast (pronóstico oficial, disponible ex-ante). Atribución pendiente de ablation.

Precisión vs. costo: el argumento completo

- LSTM: tensor 3D, hidden=32, 5,153 parámetros, normalización solo con train; ajuste total 23.3 s
- Ventanas móviles de 3 folds: train 365 días, test 168 h, orígenes a 7 días
- Sesgo de la LSTM: +314/+299/+252 MW — sub-pronóstico sistemático

DECISIÓN EJECUTIVA

No usar LSTM por defecto; justificar el costo con mejora medible bajo el mismo protocolo.

TFT-like gana por apenas 4% tras 400 segundos

+4% sobre el baseline

TFT-like (MAE 0.0131) vs. LastValue (0.0137)

DOMINIO: Tráfico · 963 sensores	DECISIÓN: Estimar sensores nuevos	HORIZONTE: 6 pasos · 10 min
BASELINE: LastValue · Lag6	RIESGO: Transferencia vs. forecast	MÉTRICA: MAE

Modelo	MAE	Tiempo
TFT-like	0.013122	398.45 s
N-BEATS	0.013360	95.41 s
LastValue	0.013671	—
LSTM	0.013817	360.58 s

Transferencia entre sensores: la pregunta correcta

- Split por sensor 770/193; cohorte ejecutada 48/24 (86,256 ventanas de train)
- LOOKBACK=72, HORIZON=6, escalado por ventana; N-BEATS 27,154 parámetros
- Sensibilidad: el bloque de la última hora domina (ΔMAE 0.0373); bloques lejanos ≈ 0

DECISIÓN EJECUTIVA

Desempate por costo: N-BEATS = 95.41 s, TFT-like = 398.45 s. Arquitecturas modernas solo si la transferencia es requisito de negocio.

Doble win: calibrada Y más angosta

-43.2% de CRPS

LightGBMQuantile vs. EmpiricalNaive, 1,428 series

DOMINIO: Planeamiento mensual	DECISIÓN: Stock · presupuesto	HORIZONTE: 18 meses oficiales
BASELINE: EmpiricalNaive	RIESGO: Bandas gaussianas sin verificar	MÉTRICA: CRPS aprox.

Modelo	CRPS	Cobertura	Ancho P10–P90
EmpiricalNaive	627.38	69.9 %	2,152.56
LightGBMQuantile	356.27	78.9 %	1,547.86

NOTA


El DeepAR quedó especificado en el contrato del capítulo, sin métrica inventada; ejecutarlo es trabajo pendiente.

Cuantiles calibrados + gobierno MLOps

- Pinball loss; cuantiles P10–P90 ordenados post hoc. Cobertura 78.9 % vs. 80 % nominal (baseline 69.9 %)
- **Umbrales:** drift MAE > 25 %, cobertura fuera 0.75–0.85, PSI > 0.25 , antigüedad > 1 periodo
- **Stack (categoría, no marca):** Evidently/NannyML · MLflow/W&B · Feast/Tecton · Airflow/Prefect
- **Olvido ante concept drift:** ventana deslizante (reacciona rápido) vs. decaimiento exponencial (conserva ciclos largos)

DECISIÓN EJECUTIVA

Entregar cuantiles calibrados y monitorear cobertura, drift y antigüedad con propietario nombrado.



Esquema conceptual — no son datos reales

Ocho experimentos por palanca, no por métrica

Cap.	Familia	Número-tótem	Palanca	Condición
2	SeasonalNaive168	MASE 0.916	Protocolo	Random split inválido: error menor
3	ETS (no ARIMA)	0.681 vs. 0.901	Selección	AIC no garantiza test
4	SARIMAX	−18.36 % MAE (*)	Covariables	Techo oracle: clima observado
5	LightGBM	MASE 0.457 (*)	Features	37 features con embargo
6	Empate 0.01 %	1.34 vs. 38.59 (29×)	Historia	Sin historia, sin escala
7	LightGBM	MASE 0.234 (*)	Covariables	Atribución abierta: DE_load_forecast
8	TFT-like / N-BEATS	+4 % MAE (*)	Arquitectura	Cohorte 48/24, no 770/193
9	LightGBM Quantile	−43.2 % CRPS	Calibración	8/8 Jarque-Bera; 78.9 % vs. 80 %

(*) asterisco de condición visible. Métricas no comparables entre capítulos — compárense las palancas, no los números.

LightGBM: el arco más elocuente del documento

- **Acto 1 — Cap. 5 (victoria):** MASE 0.457 vs. 0.818 del lineal. Features rigurosas + embargo 24 h + checklist anti-leakage.
- **Acto 2 — Cap. 6 (humillación):** empate 0.01 % contra perfil hora×día. Cross-learning no fabrica información sin historia.
- **Acto 3 — Cap. 7 (validación condicionada):** MASE 0.234 — el mejor resultado absoluto del documento. **Asterisco:** atribución abierta a `DE_load_forecast` como covariable legítima.
- **Acto 4 — Cap. 9 (coronación cuantílica):** CRPS -43.2 %; cobertura 78.9 % vs. 80 % nominal; intervalos 28 % más angostos.

DECISIÓN EJECUTIVA

La versatilidad del tabular bien alimentado es el hallazgo tecnológico más sólido del curso — no la arquitectura más sofisticada.

Las palancas que la evidencia sostiene

Palanca	Decisión	Evidencia	Magnitud	Cap.
1. Protocolo	Split temporal + embargo + test 1×	Random split en Cap. 2: error menor	necesaria	2, 5, 9
2. Features	Tabular riguroso + anti-leakage	LightGBM 37 features en Cap. 5	MASE 0.457	5
3. Historia	Warm vs. cold-start	MASE mediano 1.34 vs. 38.59	29×	6
4. Covariables	Disponibilidad futura real (no oracle)	DE_load_forecast legítimo	0.234 (*)	4, 7
5. Arquitectura	Cambio de familia	LightGBM vs. LSTM (Cap. 7); TFT-like (Cap. 8)	máx. 44 %	5, 7, 8
6. Calibración	Puntual → probabilístico	Cobertura 78.9 % vs. 80 %; intervalos 28 % angostos	−43.2 % CRPS	9

DECISIÓN EJECUTIVA

44 % máximo por modelo vs. 2 900 % por régimen de datos.

Los segundos no son el costo

Experimento	Ajuste	Cómputo	Mejora	Costo dominante
Cap. 5 — LightGBM	20.2 s	< USD 0.01	−44 % MASE vs. lineal	Ingeniería de features
Cap. 6 — LightGBM global	57.25 s	< USD 0.01	0.01 % (empate)	Historia: no comprable
Cap. 7 — LightGBM + cov.	23.3 s	< USD 0.01	0.234 vs. 0.495 (SN)	Covariable ex-ante
Cap. 8 — TFT-like	398.45 s	≈ USD 0.02	+4 % MAE vs. LastValue	Mantenimiento DL
Cap. 8 — N-BEATS	95.41 s	< USD 0.01	+2.3 % MAE vs. LastValue	Casi igual, 1/4 del tiempo

Tarifa ilustrativa USD 0.20 / vCPU-hora. El cómputo por corrida es despreciable; deciden el mantenimiento y el error evitado.

DECISIÓN EJECUTIVA

TFT-like se justifica solo si $0.04 \times Y \times D \times Z$ supera el TCO. Para el resto de la red, LastValue es la decisión financiera correcta.

Tres preguntas, tres respuestas

- **¿Cuándo paga la complejidad?** Solo con estructura explotable (Caps. 5, 9); en 4 de 8 (Caps. 2, 3, 7, 8) el modelo más sofisticado iguala o apenas supera al simple
- **¿Qué papel cumplen las exógenas?** Ayudan solo con disponibilidad futura real u oracle declarado (Caps. 4, 7)
- **¿Qué hacer con residuos no gaussianos?** Jarque-Bera rechaza normalidad en 100% de los capítulos → cuantiles empíricos (Cap. 9)

DECISIÓN EJECUTIVA

LightGBM como caballo de batalla *cuando hay features que explotar*; sin ellas empata con un promedio (Cap. 6). Baselines primero; validación temporal; cuantiles como salida estándar.

Lo que no ejecuté: tabla especificado vs. ejecutado

Especificado	Ejecutado	Cap.	Estatus
Split completo PeMS-SF 770/193	Cohorte 48/24	8	Recortado por costo de cómputo
DeepAR sobre M3	No entrenado	9	Caso emblema de honestidad documental
Few-shot 1 semana de historia	No ejecutado	6	Punto ciego warm/cold-start
Ablation sin DE_load_forecast	No ejecutado	7	Deuda 1: atribución del 0.234 (§10.8)
GRU como comparador LSTM	No entrenada	7	Omitida por presupuesto

NOTA

Política: cuando una especificación no se ejecuta, se documenta como tal — no se reescribe como resultado.

Madurez epistémica alcanzada: evidencia verificada en entorno relevante (RRL 4), con elementos del escalón superior en los experimentos multi-fold (Caps. 4, 5, 7). No se declara una madurez mayor a la evidenciada.

Cuatro acciones en orden — y lo que no haría

1. **Calcular siempre un baseline alineado por timestamp** antes de cualquier modelo complejo. En la mitad de los capítulos (2, 3, 7, 8) fue difícil de superar.
2. **Auditar features y covariables antes de elegir arquitectura.** Palanca de features (-44%) e historia ($29\times$) $>$ palanca de arquitectura (máx. 44%).
3. **Validación temporal obligatoria con test consultado una sola vez.** El split inválido produjo error **menor**, no mayor (Cap. 2).
4. **Pasar a cuantiles empíricos como salida estándar** (Jarque-Bera rechazado en 100% de los diagnósticos). Monitorear cobertura $0.75\text{--}0.85$, $\text{PSI} > 0.25$ con propietario nombrado.

DECISIÓN EJECUTIVA

Lo que no haría: empezar por la arquitectura. La elección de modelo es la palanca de menor magnitud verificada en este documento — invertir primero en protocolo, features, historia y covariables.

¿Cuánto del 0.234 es LightGBM y cuánto es `DE\_load\_forecast`?

- El mejor resultado absoluto (MASE 0.234, Cap. 7) usa el pronóstico oficial de carga, disponible ex-ante (no es oracle)
- **Protocolo de ablation (§10.8):** quitar `DE_load_forecast`, reentrenar 3 folds, `SEED = 42`, mismo embargo
- **Regla de decisión:** $\text{MASE} > 0.40 \rightarrow$ victoria de la covariable; $\text{MASE} < 0.30 \rightarrow$ victoria tabular; $0.30\text{--}0.40 \rightarrow$ atribución mixta (no reclamar el 0.234)

NOTA

Si solo pudiera ejecutar un experimento más, sería este. El ranking de LightGBM no se discute; se discute la magnitud atribuible.

¿Es el 4 % de mejora real o un artefacto de la cohorte 48/24?

- La cohorte ejecutada fue 48 sensores de train, 24 de test — no la 770/193 especificada originalmente
- La diferencia de 4 % entre TFT-like (0.013122) y LastValue (0.013671) cae dentro del rango plausible de variabilidad entre cohortes
- **Deuda:** re-ejecutar la cohorte completa 770/193 para verificar si el ranking práctico entre N-BEATS y TFT-like se mantiene

NOTA

La honestidad estructural del documento descansa en admitir esto: el 4 % no es un número definitivo, es una lectura parcial de un experimento recortado.

¿Por qué no se pueden comparar 0.916 con 0.234 con 0.013?

- Datasets distintos (tráfico horario, energía residencial 10 min, PM2.5 horario, bicicletas horarias, 370 series eléctricas, carga nacional, 963 sensores viales, 1 428 series M3)
- Protocolos distintos (temporal 80/20, 70/15/15, rolling-origin 3 folds, walk-forward con embargo, cold-start por serie, ventanas móviles, split por sensor, holdout oficial M3)
- Estadísticos distintos (MASE puntual, MASE macro mediano, MAE absoluto, CRPS aproximado)
- Escalas de target distintas (vehículos/hora, Wh, $\mu\text{g}/\text{m}^3$, alquileres, kW, MW normalizado, ocupación 0-1, valor M3)

DECISIÓN EJECUTIVA

Compárense las palancas (protocolo, features, historia, covariables, arquitectura, calibración), no los números. La Tabla 10.1 lo advierte explícitamente.

Gracias — preguntas y discusión

1. La jerarquía de palancas se fundamenta en evidencia de los ocho capítulos
2. Ningún hallazgo sustituye la validación independiente en el dominio de aplicación

44 % vs. 2 900 %

La asimetría que organiza todo el documento.

Declaración de integridad: los ocho datasets son públicos o de competencia, con licencias documentadas (Apéndice A/F de la monografía). No se usaron datos sensibles ni identificables. Redacción y edición asistidas por IA (Claude, Anthropic) bajo supervisión humana; ninguna métrica reportada fue generada por IA — todas provienen de la ejecución real de los notebooks. Sin conflictos de interés declarados.