

Sílabo del curso

Forecasting de Series Temporales: De Modelos Paramétricos a Deep Learning en Producción

Contenido

Datos generales	2
Sumilla	2
Competencias y objetivos de aprendizaje	2
Perfil de ingreso y prerequisites	2
Metodología: Business y Code-First	2
Stack tecnológico recomendado	3
Cómo leer este curso para profesionales de industria	4
Casos de negocio del curso	4
Preguntas guía por semana	4
Anti-patrones por clase	4
Métricas técnicas y su traducción a negocio	5
Criterio de escalamiento de complejidad	5
Criterio profesional del curso	5
Programa analítico de 8 clases	6
Semana 1: Fundamentos de negocio, EDA temporal y baselines	6
Semana 2: Modelos paramétricos I: ARMA y ARIMA	6
Semana 3: Modelos paramétricos II: SARIMA y variables exógenas	7
Semana 4: Machine Learning I: Feature engineering temporal y validación	8
Semana 5: Machine Learning II: Gradient Boosting y modelos globales	9
Semana 6: Deep Learning I: Redes secuenciales LSTM y GRU	10
Semana 7: Deep Learning II: N-BEATS y Temporal Fusion Transformers	11
Semana 8: Forecasting probabilístico, MLOps y monitoreo	12
Sistema de evaluación	14
Equivalencias de casos por industria	14
Proyecto final integrador	14
Política de integridad y uso de IA	15
Bibliografía consolidada	16

Datos generales

Nombre del curso	Forecasting de Series Temporales Aplicado a la Industria
Duración	8 semanas o 8 módulos, 40 a 48 horas lectivas más trabajo autónomo
Modalidad	Híbrida u online, con sesiones code-along y resolución de casos de negocio
Enfoque	Profesional, pragmático y orientado a producción, no académico
Lenguaje principal	Python

Sumilla

El curso proporciona un marco de trabajo integral para la predicción de series temporales en entornos empresariales reales. A diferencia de los cursos tradicionales centrados en demostraciones matemáticas, este programa prioriza la toma de decisiones basada en datos, la ingeniería de características temporales, la robustez de los modelos y su despliegue en producción.

El estudiante transitará desde la definición del problema de negocio y los modelos estadísticos clásicos, como ARIMA y SARIMA, pasando por el estado del arte en Machine Learning tabular, hasta arquitecturas modernas de Deep Learning, como N-BEATS y Temporal Fusion Transformers. El curso culmina con estrategias de forecasting probabilístico, monitoreo de modelos y MLOps.

Competencias y objetivos de aprendizaje

Al finalizar el curso, el profesional será capaz de:

1. Traducir problemas de negocio, como inventarios, demanda, finanzas o capacidad, a problemas técnicos de forecasting, definiendo métricas de error alineadas al impacto empresarial.
2. Diseñar pipelines de validación temporal robustos, eliminando fugas de información y aplicando backtesting riguroso.
3. Implementar y comparar modelos estadísticos, Machine Learning y Deep Learning, justificando la elección del modelo según costo computacional, mantenibilidad y mejora marginal.
4. Generar pronósticos probabilísticos, incluyendo cuantiles e intervalos de predicción, para la gestión de riesgos e inventarios de seguridad.
5. Desplegar y monitorear modelos en producción, detectando data drift y concept drift, y definiendo estrategias de reentrenamiento.

Perfil de ingreso y prerequisites

- **Público objetivo:** Data Scientists, ML Engineers, Data Analysts Senior, planificadores de demanda, analistas de Supply Chain, analistas financieros y profesionales de operaciones.
- **Requisitos técnicos:**
 - Programación intermedia en Python, especialmente pandas y NumPy.
 - Conocimientos básicos de estadística inferencial.
 - Familiaridad con SQL y entornos de notebooks.
- **Nota:** No se requiere conocimiento avanzado de cálculo multivariable, ecuaciones diferenciales ni demostraciones matemáticas.

Metodología: Business y Code-First

- **Cero demostraciones manuales:** Se asume la matemática subyacente y se enfatiza la interpretación de supuestos, resultados y limitaciones operativas.

- **Aprendizaje basado en casos:** Cada clase resuelve una fricción real de la industria, por ejemplo, promociones que rompen la estacionalidad, quiebres de stock o cambios estructurales.
- **Cultura del baseline:** Se penaliza la complejidad innecesaria. Todo modelo avanzado debe justificar su uso superando a baselines simples como Seasonal Naive o medias móviles.
- **Orientación a producción:** El curso prioriza modelos reproducibles, monitoreables, documentados y alineados con decisiones de negocio.

Stack tecnológico recomendado

Capa	Herramientas sugeridas
Manipulación y feature engineering	pandas, polars, tsfresh
Modelos estadísticos y baselines	statsforecast, sktime, statsmodels
Machine Learning	LightGBM, XGBoost, scikit-learn, Optuna
Deep Learning	PyTorch, pytorch-forecasting, neuralforecast
MLOps y tracking	MLflow, Evidently AI, DVC
Visualización	Plotly, Streamlit, Gradio

Cómo leer este curso para profesionales de industria

Este curso no evalúa modelos por complejidad matemática, sino por su utilidad para tomar decisiones. Cada clase incluye un caso de negocio con datos reales, una pregunta operativa, un baseline obligatorio, una validación temporal correcta y un entregable ejecutable. El alumno debe demostrar que entiende el problema, los datos, el riesgo de fuga de información y el impacto de negocio del modelo elegido.

Casos de negocio del curso

El curso utiliza ocho casos industriales reales, cada uno asociado a una semana: tráfico, energía residencial, calidad del aire, micromovilidad, clientes de energía, carga nacional, sensores viales y planeamiento probabilístico.

Semana	Caso de clase	Pregunta de negocio	Entregable
1	Tráfico horario	¿Cuándo reforzar operación?	Dashboard EDA + baselines
2	Consumo energético	¿ARIMA supera a modelos simples?	Memo comparativo
3	Calidad del aire	¿Las exógenas estarán disponibles?	Matriz de covariables
4	Bicicletas compartidas	¿Cómo evitar leakage?	Feature store temporal
5	Clientes nuevos	¿Cómo predecir sin historia?	Política cold-start
6	Carga nacional	¿LSTM vale la pena?	Tabla precisión/costo
7	Sensores nuevos	¿Cómo transferir a sensores nuevos?	Recomendación arquitectura
8	Planeamiento mensual	¿Qué intervalo usar?	Motor probabilístico + MLOps

Preguntas guía por semana

Semana	Pregunta guía
1	¿Qué tan difícil es este problema si solo uso reglas simples?
2	¿Cuándo ARIMA vale la pena frente a modelos simples?
3	¿Las variables exógenas estarán disponibles en producción?
4	¿Cómo construimos features sin filtrar información futura?
5	¿Cuándo un modelo global ayuda y cuándo no?
6	¿Deep Learning justifica su costo?
7	¿Cómo predecir series nunca vistas?
8	¿Cómo comunicar incertidumbre para decidir con riesgo?

Anti-patrones por clase

Semana	Anti-patrón a evitar
1	Usar random split en series temporales
2	Elegir modelo solo por AIC

Semana	Anti-patrón a evitar
3	Usar clima observado como si fuera futuro
4	Ventanas móviles centradas o componentes del target como features
5	Modelo global sin historia del cliente nuevo
6	LSTM por defecto
7	Usar Transformer sin comparar con baseline simple
8	Intervalos gaussianos sin verificar cobertura

Métricas técnicas y su traducción a negocio

Métrica técnica	Traducción de negocio
MAE	Error promedio en unidades operativas
RMSE	Sensibilidad a errores grandes
MASE	¿El modelo supera al naive estacional?
WAPE	Error relativo al volumen total
Cobertura P10–P90	¿El intervalo contiene la realidad con la frecuencia prometida?
PSI	¿Cambió la distribución del error o de los datos?

Criterio de escalamiento de complejidad

No se aprueba por usar el modelo más complejo. El alumno debe demostrar que un modelo más complejo supera a un baseline bajo validación temporal correcta.

Nivel	Descripción
Nivel 0	Baseline obligatorio (Naive, Seasonal Naive, media móvil).
Nivel 1	Modelo estadístico simple (ARIMA, SARIMA, SARIMAX).
Nivel 2	Machine Learning tabular con feature engineering temporal (LightGBM, XGBoost).
Nivel 3	Deep Learning secuencial (LSTM, GRU), solo si justifica su costo.
Nivel 4	Arquitecturas modernas (N-BEATS, TFT), si hay transferencia o múltiples horizontes.
Nivel 5	Forecasting probabilístico y monitoreo para producción.

Criterio profesional del curso

No se aprueba por usar el modelo más complejo. Se aprueba por demostrar:

- Validación temporal correcta.
- Baselines comparados.
- Ausencia de fuga de información.
- Métricas alineadas al negocio.
- Riesgos documentados.
- Plan de monitoreo o reentrenamiento.

Programa analítico de 8 clases

Semana 1: Fundamentos de negocio, EDA temporal y baselines

- **Tópico cerrado:** Anatomía de las series temporales, definición del problema de negocio, métricas de error y construcción de baselines.
- **Caso de clase:** Predicción de tráfico horario para dimensionar recursos operativos.
- **Pregunta de negocio:** ¿Cuántos vehículos se esperan por hora y en qué momentos del día/semana se deben reforzar recursos?
- **Decisión que habilita:** Asignación de turnos, apertura de carriles, programación de mantenimiento y gestión de contingencias.
- **Datos del caso:** Metro Interstate Traffic Volume, frecuencia horaria, con duplicados, gaps y variables meteorológicas observadas.
- **Riesgo técnico principal:** Usar random split puede producir métricas artificialmente mejores, pero inválidas para producción.
- **Baseline obligatorio:** Naive, Seasonal Naive 24, Seasonal Naive 168, medias móviles.
- **Lección clave del experimento:** Un Seasonal Naive bien alineado por timestamp puede ser muy difícil de superar. En el caso documentado, SeasonalNaive168 logra MASE de 0.916 y supera a ETS, medias móviles y Naive.
- **Anti-patrón a evitar:** Usar random split. La partición aleatoria produce un MAE menor (251.66) que la temporal (287.55), no porque sea mejor, sino porque filtra información del futuro hacia el entrenamiento.
- **Contenidos principales:**
 - Componentes de una serie: tendencia, estacionalidad, ciclicidad y ruido.
 - Definición de horizonte de pronóstico y frecuencia de decisión.
 - Métricas: MAE, RMSE, MASE, WAPE y limitaciones de MAPE.
 - Baselines: Naive, Seasonal Naive, media móvil y promedio móvil estacional.
 - Riesgo de random split y validación temporal.
- **Actividad práctica:** Construcción de un análisis exploratorio temporal y reporte de baselines para el caso de tráfico.
- **Entregable:** Dashboard de EDA y tabla comparativa de errores por horizonte.
- **Criterio de aceptación:** El estudiante demuestra que el split es temporal, no aleatorio; los baselines respetan la estructura temporal; Seasonal Naive está alineado por timestamp; y el error se comunica en términos operativos.
- **Conexión con producción:** Si el baseline estacional ya captura la mayor parte de la señal, un modelo complejo debe justificar su costo antes de ser considerado.
- **Referencia APA:**

Nielsen, A. (2019). *Practical time series analysis*. O'Reilly Media. Capítulo 2, pp. 21-45; Capítulo 3, pp. 47-72.

Semana 2: Modelos paramétricos I: ARMA y ARIMA

- **Tópico cerrado:** Modelos ARMA y ARIMA, estacionariedad, identificación de órdenes y diagnóstico de residuos.
- **Caso de clase:** Predicción de consumo energético residencial.
- **Pregunta de negocio:** ¿Vale la pena construir un ARIMA formal o un modelo simple es suficiente?

- **Decisión que habilita:** Dimensionar capacidad, detectar picos y planificar recursos de energía.
- **Datos del caso:** Appliances Energy Prediction, frecuencia horaria (agregada desde 10 min), target: consumo de electrodomésticos.
- **Riesgo técnico principal:** Elegir modelo solo por AIC/BIC sin validación temporal.
- **Baseline obligatorio:** Seasonal Naive 24, ETS, Theta.
- **Lección clave del experimento:** Hacer el procedimiento formalmente correcto no garantiza ganar. ARIMA(1,0,2) seleccionado correctamente por AIC pierde frente a ETS (MASE 0.681), Theta (0.748) y SeasonalNaive24 (0.834); ARIMA obtiene MASE 0.901 en test.
- **Anti-patrón a evitar:** Elegir modelo solo por AIC/BIC sin validación temporal. Los cinco candidatos con menor AIC fueron prácticamente indistinguibles en validation (MAE 302).
- **Contenidos principales:**
 - Estacionariedad y diferenciación.
 - Procesos AR, MA y ARMA.
 - Identificación de órdenes mediante ACF y PACF.
 - ARIMA(p, d, q).
 - Diagnóstico de residuos y pruebas de ruido blanco.
- **Actividad práctica:** Implementación de un pipeline ARIMA con grid search en train, selección por AIC/BIC en train y MAE en validation, evaluación final en test una sola vez, y comparación contra ETS, Theta y Seasonal Naive.
- **Entregable:** Memo ejecutivo de una página con modelo seleccionado, métricas en validación, métricas finales en test, diagnóstico de residuos y recomendación: ¿usar ARIMA o una alternativa más simple?
- **Criterio de aceptación:** El estudiante demuestra que el test se consultó una sola vez, que la selección usó validation (no solo AIC) y que el diagnóstico de residuos incluye Ljung-Box a múltiples lags.
- **Conexión con producción:** El error se concentra en los picos de consumo (MAE en Q4 = 572 vs. Q2 = 163), los más relevantes para dimensionar capacidad.
- **Referencia APA:**

Box, G. E. P., Jenkins, G. M., Reinsel, G. C. & Ljung, G. M. (2015). *Time series analysis: forecasting and control* (5th ed.). Wiley. Capítulo 3, pp. 47-78; Capítulo 4, pp. 79-107.

Semana 3: Modelos paramétricos II: SARIMA y variables exógenas

- **Tópico cerrado:** Estacionalidad, SARIMA y modelos con variables exógenas.
- **Caso de clase:** Alerta temprana de calidad del aire (PM2.5).
- **Pregunta de negocio:** ¿Cuánto mejora el pronóstico al usar variables meteorológicas y estarán realmente disponibles en producción?
- **Decisión que habilita:** Activar alertas, restringir operaciones o proteger actividades sensibles.
- **Datos del caso:** Beijing PM2.5, frecuencia horaria. Target: concentración PM2.5. Covariables: temperatura, punto de rocío, presión, viento, lluvia/nieve, dirección del viento.
- **Riesgo técnico principal:** Tratar una variable observada (clima) como si fuera conocida a futuro. En producción se necesita un pronóstico meteorológico externo.
- **Baseline obligatorio:** SARIMA sin exógenas.
- **Lección clave del experimento:** SARIMAX reduce el MAE en los tres folds (19.9%, 12.2%, 23.0%), para una mejora media de 18.36% en MAE, pero bajo escenario oracle (clima observado). La mejora real en producción dependerá de la calidad del pronóstico meteorológico externo.

- **Anti-patrón a evitar:** Usar clima observado en test como si fuera futuro. Es un escenario oracle: la mejora medida es un límite superior optimista.
- **Contenidos principales:**
 - Estacionalidad aditiva y multiplicativa.
 - Diferenciación estacional.
 - SARIMA(p, d, q)(P, D, Q)s.
 - SARIMAX y regresores externos.
 - Uso de feriados, promociones, precio y calendario.
 - Disponibilidad futura de covariables: observado vs. disponible ex-ante.
- **Actividad práctica:** Modelamiento SARIMA vs SARIMAX con rolling-origin (3 folds), tratamiento causal de nulos (forward fill limitado, sin información futura) y evaluación de estabilidad entre folds.
- **Entregable:** Matriz de disponibilidad de covariables: para cada variable, indicar si está en el histórico, si estará disponible en producción y qué hacer si no lo está.
- **Criterio de aceptación:** El estudiante demuestra que la imputación se ajusta dentro de cada fold (no sobre la serie completa), que SARIMAX se evalúa con rolling-origin y que se documenta explícitamente el escenario oracle.
- **Conexión con producción:** La cobertura empírica de intervalos al 95% nominal fue 76.8%, 68.5% y 86.3% por fold —ningún fold alcanzó la cobertura nominal—, lo que motiva el paso al forecasting probabilístico en la Semana 8.
- **Referencia APA:**
Shumway, R. H. & Stoffer, D. S. (2017). *Time series analysis and its applications: with R examples* (4th ed.). Springer. Capítulo 3, pp. 111-145; Capítulo 6, pp. 321-342.

Semana 4: Machine Learning I: Feature engineering temporal y validación

- **Tópico cerrado:** Transformación de series temporales en problemas supervisados y validación temporal rigurosa.
- **Caso de clase:** Rebalanceo de bicicletas compartidas.
- **Pregunta de negocio:** ¿Qué características del pasado reciente permiten predecir la demanda sin filtrar información futura?
- **Decisión que habilita:** Redistribuir flota, evitar estaciones vacías en horas pico y reducir costos operativos.
- **Datos del caso:** Bike Sharing UCI, frecuencia horaria. Target: cnt (número de alquileres por hora). El dataset contiene casual y registered que sumados reconstruyen exactamente el target.
- **Riesgo técnico principal:** Leakage por ventanas móviles centradas o por usar componentes algebraicos del target (casual + registered = cnt) como features.
- **Baseline obligatorio:** Linear, Ridge (con lags y rolling windows bien contruidos).
- **Lección clave del experimento:** Cuando el feature engineering es riguroso, el machine learning tabular entrega ganancias grandes y estables. LightGBM alcanza MASE 0.457 ± 0.117 frente a 0.818 ± 0.097 de Ridge, una reducción de 44% en MASE con $R^2 > 0.95$.
- **Anti-patrón a evitar:** Ventanas móviles centradas (usan información futura) o usar casual/registered como features (fuga directa del target).
- **Contenidos principales:**
 - Conversión de series a tablas supervisadas.
 - Lags con `shift()`, rolling statistics sobre el pasado.

- Variables de calendario y codificación cíclica (sen/cos).
- Data leakage y embargo temporal entre train y test.
- Walk-forward validation y time series cross-validation.
- Checklist anti-leakage: lags con shift, rolling sobre pasado, escalador solo en train, embargo, exclusión de componentes del target.
- **Actividad práctica:** Construcción de un feature store temporal con lags, rolling windows, codificación cíclica y pipeline de validación walk-forward con embargo de 24 h. Comparación de Linear, Ridge, Random Forest y LightGBM.
- **Entregable:** Feature store reusable con lista de features, fórmula de construcción, auditoría anti-leakage (si usa o no información futura) y tabla comparativa de modelos con MASE por fold.
- **Criterio de aceptación:** El estudiante demuestra que toda rolling window usa solo el pasado, que casual/registered no aparecen como features, que el escalador se ajusta solo en train y que el embargo temporal separa train de test.
- **Conexión con producción:** El error se concentra en horas pico (MAE 43.67 en pico vs. 20.85 en valle), lo que orienta la prioridad operativa del rebalanceo.
- **Referencia APA:**
Lazzeri, F. (2020). *Machine learning for time series forecasting with Python*. O'Reilly Media. Capítulo 4, pp. 71-102; Capítulo 5, pp. 103-130.

Semana 5: Machine Learning II: Gradient Boosting y modelos globales

- **Tópico cerrado:** Modelos de gradient boosting para forecasting y aprendizaje conjunto entre múltiples series.
- **Caso de clase:** Clientes nuevos de energía sin historial (cold-start).
- **Pregunta de negocio:** ¿Puede un modelo global predecir el consumo de un cliente que nunca vio durante el entrenamiento?
- **Decisión que habilita:** Dimensionar capacidad, ofertas comerciales o recursos de atención para clientes industriales nuevos.
- **Datos del caso:** Electricity Load Diagrams, 370 clientes, frecuencia horaria. Split: 296 clientes entrenan, 74 quedan completamente fuera (cold-start estricto por serie).
- **Riesgo técnico principal:** Asumir que un modelo global resuelve cold-start automáticamente. Sin historia del cliente, ningún modelo recupera la escala individual.
- **Baseline obligatorio:** Perfil hora×día (media de train por día y hora) — baseline transparente.
- **Lección clave del experimento:** El modelo global (LightGBM con 250 árboles) empata con el baseline de perfil hora×día: MAE 3178.39 vs. 3178.72 (diferencia de 0.01%). En warm-start local con historia, el MASE mediano es 1.34; en cold-start estricto, 38.59 —casi 29 veces peor—. La disponibilidad de historia domina sobre la elección de arquitectura.
- **Anti-patrón a evitar:** Creer que un modelo global automáticamente resuelve clientes nuevos. El cold-start estricto prohíbe, por definición, lags, identificador y target encoding del cliente nuevo.
- **Contenidos principales:**
 - XGBoost y LightGBM aplicados a series temporales.
 - Pronóstico directo versus pronóstico recursivo.
 - Modelos locales, jerárquicos y globales.
 - Cross-learning y transferencia entre series.
 - Interpretación con feature importance y SHAP.

- Cold-start vs. warm-start: límites del cross-learning.
- **Actividad práctica:** Lectura por chunks de un dataset grande (9.7M filas), clustering por perfil de consumo, split por cliente (296/74), modelo global solo con calendario, baseline transparente de perfil hora×día y contraste con warm-start local.
- **Entregable:** Política de pronóstico para clientes nuevos: si cliente tiene 0 historia → perfil hora×día; si tiene 1 semana → few-shot adaptation; si tiene 4+ semanas → modelo local/global con rezagos.
- **Criterio de aceptación:** El estudiante demuestra que el split es por cliente (no temporal), que el cold-start no usa lags ni identificador del cliente nuevo y que el modelo global se comparó contra un baseline transparente.
- **Conexión con producción:** La brecha warm-start vs. cold-start (MASE 1.34 vs. 38.59) es mayor que cualquier diferencia entre familias de modelos en cualquier otro capítulo del curso.
- **Referencias APA:**
Lazzeri, F. (2020). *Machine learning for time series forecasting with Python*. O'Reilly Media. Capítulo 6, pp. 131-168.
Chen, T. & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785-794.

Semana 6: Deep Learning I: Redes secuenciales LSTM y GRU

- **Tópico cerrado:** Introducción a Deep Learning para series temporales usando redes recurrentes.
- **Caso de clase:** Carga eléctrica nacional con renovables.
- **Pregunta de negocio:** ¿Conviene usar LSTM para capturar dependencias temporales o basta con modelos tabulares bien diseñados?
- **Decisión que habilita:** Predecir la carga eléctrica nacional para despacho, considerando generación solar y eólica.
- **Datos del caso:** OPSD Germany, frecuencia horaria. Target: carga eléctrica nacional (MW). Covariables: pronóstico oficial de carga, generación solar, eólica (onshore/offshore).
- **Riesgo técnico principal:** Usar LSTM por defecto. Deep Learning requiere más infraestructura, más costo computacional y más esfuerzo de mantenimiento.
- **Baseline obligatorio:** Seasonal Naive 168.
- **Lección clave del experimento:** LSTM no supera a LightGBM y queda por debajo incluso del Seasonal Naive. LightGBM logra $MASE\ 0.234 \pm 0.015$, Seasonal Naive 0.495 ± 0.218 y LSTM 0.576 ± 0.046 . ARIMA(2,1,2) simple obtiene 3.263.
- **Anti-patrón a evitar:** Usar LSTM por defecto. La LSTM no ganó ninguna comparación directa en este curso.
- **Contenidos principales:**
 - Representación de secuencias y tensores 3D (muestras × 168 pasos × features).
 - Redes RNN, LSTM y GRU.
 - Problemas de vanishing gradient y overfitting.
 - Normalización ajustada solo en train, early stopping y regularización.
 - Cuándo usar y cuándo no usar LSTM.
- **Actividad práctica:** Construcción de tensores 3D con lookback semanal, escalado ajustado solo en train, entrenamiento de LSTM simple (hidden=32, 5153 parámetros) y comparación contra Seasonal Naive, LightGBM y ARIMA. Medición de tiempo de entrenamiento.

- **Entregable:** Tabla de decisión con precisión (MASE), costo computacional (tiempo de ajuste) y complejidad (¿requiere tensor secuencial?) por modelo, con recomendación explícita.
- **Criterio de aceptación:** El estudiante demuestra que el escalador se ajusta solo en train, que el tensor tiene la forma correcta (muestras $\times$ 168 $\times$ features) y que la comparación incluye costo computacional, no solo precisión.
- **Conexión con producción:** El deep learning debe justificar su costo de infraestructura frente a LightGBM y frente al seasonal naive; no debe asumirse superior por defecto.
- **Referencia APA:**
Chollet, F. (2021). *Deep learning with Python* (2nd ed.). Manning. Capítulo 10, pp. 293-330.

Semana 7: Deep Learning II: N-BEATS y Temporal Fusion Transformers

- **Tópico cerrado:** Arquitecturas modernas de Deep Learning diseñadas específicamente para forecasting.
- **Caso de clase:** Sensores de tráfico nuevos (transferencia entre series).
- **Pregunta de negocio:** ¿Cómo predecir series que nunca fueron vistas durante el entrenamiento?
- **Decisión que habilita:** Estimar el comportamiento de sensores nuevos usando sensores similares ya existentes.
- **Datos del caso:** PeMS-SF, 963 sensores, frecuencia intradía. Target: ocupación vial por sensor. Sin fechas calendario reales. Split por sensor: sensores de entrenamiento vs. sensores de test nunca vistos.
- **Riesgo técnico principal:** Confundir transferencia entre sensores con forecasting temporal clásico. El problema no es solo temporal, es de transferencia.
- **Baseline obligatorio:** LastValue, Lag6.
- **Lección clave del experimento:** TFT-like gana con MAE 0.013122 frente al baseline LastValue (0.013671), una mejora de apenas 4.0% tras 400 s de entrenamiento y 9697 parámetros. N-BEATS alcanza casi lo mismo (0.013360) en una cuarta parte del tiempo. LSTM pierde contra el baseline LastValue.
- **Anti-patrón a evitar:** Usar Transformer sin comparar con baseline simple. La ganancia marginal sobre un baseline trivial puede ser muy pequeña.
- **Contenidos principales:**
 - N-BEATS para forecasting univariado interpretable (apilamiento residual).
 - Temporal Fusion Transformers para múltiples horizontes (atención temporal y gating).
 - Autoatención vs. recurrencia: qué resuelve cada mecanismo.
 - Interpretabilidad para stakeholders.
 - Evaluación de complejidad versus beneficio.
 - Etiquetado honesto: un TFT-like no es un TFT completo.
- **Actividad práctica:** Split por sensor, construcción de ventanas, entrenamiento de N-BEATS compacto (27 154 parámetros), LSTM pequeña (4513 parámetros) y TFT-like (9697 parámetros). Medición de tiempo de entrenamiento (854.4 s total) y sensibilidad temporal por permutación.
- **Entregable:** Recomendación ejecutiva: ¿vale la pena usar TFT-like? ¿N-BEATS ofrece mejor costo/beneficio? ¿En qué casos conviene un baseline simple? Incluir tabla de MAE, WAPE y tiempo de ajuste por modelo.

- **Criterio de aceptación:** El estudiante demuestra que el split es por sensor (no temporal), que los baselines LastValue y Lag6 se evaluaron primero y que la comparación incluye costo computacional, no solo precisión.
- **Conexión con producción:** La ganancia de 4% sobre el baseline trivial puede no justificar la infraestructura de deep learning en un contexto de recursos acotados.
- **Nota:** Las cifras corresponden a la cohorte CPU 48/24 ejecutada, no al split completo 770/193 definido pero no ejecutado.
- **Referencias APA:**
 Lim, B., Arık, S. Ö., Loeff, N. & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4), pp. 1748-1764.
 Oreshkin, B. N., Carпов, D., Chapados, N. & Bengio, Y. (2020). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. *International Conference on Learning Representations*.

Semana 8: Forecasting probabilístico, MLOps y monitoreo

- **Tópico cerrado:** Pronóstico probabilístico, despliegue, monitoreo y gobernanza de modelos en producción.
- **Caso de clase:** Planeamiento mensual con incertidumbre.
- **Pregunta de negocio:** ¿Qué intervalo de predicción debo usar para tomar decisiones con riesgo controlado?
- **Decisión que habilita:** Definir stock de seguridad, presupuesto o capacidad con intervalos probabilísticos calibrados.
- **Datos del caso:** M3 Monthly, 1428 series mensuales, holdout oficial de 18 meses. Sin covariables. Target: series mensuales del benchmark M3.
- **Riesgo técnico principal:** Asumir normalidad de residuos y entregar intervalos gaussianos sin validación de cobertura. En los 8 capítulos con diagnóstico, Jarque-Bera rechazó normalidad en el 100% de los casos.
- **Baseline obligatorio:** EmpiricalNaive (último valor + cuantiles empíricos de la diferencia estacional de 12 meses).
- **Lección clave del experimento:** LightGBMQuantile reduce el CRPS aproximado en 43.2% frente al baseline empírico (356.27 vs. 627.38), con cobertura empírica de 78.9% (más cercana al 80% nominal que el baseline de 69.9%) e intervalos más angostos (1547.86 vs. 2152.56). El forecasting probabilístico es la ganancia más clara del curso para producción.
- **Anti-patrón a evitar:** Intervalos gaussianos sin verificar cobertura. Asumir normalidad cuando los residuos casi nunca son normales ni homocedásticos.
- **Contenidos principales:**
 - Predicción puntual versus predicción probabilística.
 - Cuantiles P10, P25, P50, P75 y P90.
 - Intervalos de predicción, Pinball Loss y CRPS aproximado.
 - Cobertura empírica y ancho de intervalo (sharpness).
 - LightGBM Quantile vs. baseline empírico.
 - Data drift, concept drift, PSI y degradación de modelos.
 - Model card, reentrenamiento, alertas y reglas de monitoreo.

- **Actividad práctica:** Construcción de un motor de pronóstico probabilístico con 5 cuantiles, evaluación con Pinball Loss, CRPS aproximado y cobertura empírica. Simulación de drift (+20% en el último tercio del target) y construcción de dashboard de monitoreo con umbrales explícitos.
- **Entregable:** Panel probabilístico con pronóstico P10/P50/P90, cobertura empírica, ancho de intervalo, reglas de reentrenamiento (umbral de drift de MAE > 25%, cobertura fuera de 0.75–0.85, PSI > 0.25) y model card.
- **Criterio de aceptación:** El estudiante demuestra que se evaluó cobertura empírica contra el nivel nominal, que los cuantiles no presentan cruces y que el plan de monitoreo incluye umbrales explícitos, un propietario nombrado y acciones concretas ante cada alerta.
- **Conexión con producción:** Un dashboard sin umbrales explícitos, propietario nombrado y acciones concretas no constituye gobierno de modelos.
- **Nota:** No se reportan métricas de DeepAR porque no se ejecutó; documentar una especificación no ejecutada como si fuera un resultado sería un error grave.
- **Referencias APA:**

Gneiting, T. & Katzfuss, M. (2014). Probabilistic forecasting. *Annual Review of Statistics and Its Application*, 1, pp. 125-151.

Treveil, M., et al. (2020). *Introducing MLOps: practical machine learning for production*. O'Reilly Media. Capítulo 6, pp. 105-128.

Sistema de evaluación

Los ocho casos de clase alimentan los entregables del curso:

- Semana 1-2: laboratorio de baselines y ARIMA.
- Semana 3-4: laboratorio de exógenas y feature engineering.
- Semana 5-7: laboratorio de modelos globales y deep learning.
- Semana 8: laboratorio probabilístico y MLOps.

Instrumento	Descripción	Peso
Laboratorio 1	Caso tráfico + ARIMA: EDA temporal, baselines y ARIMA con diagnóstico	15%
Laboratorio 2	Caso PM2.5 + feature engineering: exógenas, SARIMAX y walk-forward	15%
Laboratorio 3	Caso global + LSTM/Transformer: modelos globales, cold-start y deep learning	15%
Laboratorio 4	Caso probabilístico + MLOps: cuantiles, cobertura y monitoreo	15%
Reporte de benchmarking	Comparación ejecutiva entre baselines, modelos estadísticos y Machine Learning	20%
Proyecto final integrador	Pipeline completo de forecasting con validación temporal y salida probabilística	35%
Presentación a stakeholders	Defensa oral del modelo, supuestos, riesgos y retorno de negocio	15%

Equivalencias de casos por industria

Como el curso está dirigido a profesionales de industria, cada alumno puede adaptar el caso a su propio dominio:

Industria	Caso equivalente	Pregunta típica
Retail	Demanda por tienda/SKU	¿Cuánto reponer y cuándo?
Energía	Consumo/carga	¿Cuánta capacidad debo contratar?
Logística	Tráfico/flotas	¿Cuándo habrá congestión o necesidad de vehículos?
Finanzas	Flujo de caja/riesgo	¿Qué intervalo de pérdida espero?
Operaciones	Capacidad/turnos	¿Cuánto personal necesito por turno?
Mantenimiento	Fallas/condición	¿Cuándo aumenta el riesgo de falla?

Proyecto final integrador

El reto: El alumno recibirá un dataset crudo y realista de una empresa de retail, energía, logística o finanzas. El dataset contendrá missing values, outliers, promociones, cambios de precio y múltiples series.

Entregables requeridos:

1. Repositorio de código con estructura modular, entorno virtual y documentación.
2. Pipeline de feature engineering temporal sin fugas de información.
3. Experimento de backtesting con walk-forward validation o cross-validation temporal.

4. Comparación de al menos tres familias de modelos: baseline, estadístico y Machine Learning o Deep Learning.
5. Salida probabilística con cuantiles o intervalos de predicción.
6. Model card con supuestos, limitaciones, métricas y plan de monitoreo.
7. Presentación ejecutiva traduciendo el error técnico a impacto de negocio.

Criterio profesional de aprobación: No se aprueba por usar el modelo más complejo, sino por demostrar validación correcta, robustez, utilidad para la decisión, reproducibilidad y claridad en la comunicación.

Política de integridad y uso de IA

Se permite y fomenta el uso de asistentes de IA para depurar código, explicar errores y generar ejemplos. Sin embargo, el alumno es responsable de entender y defender cada componente de su solución. En particular, deberá demostrar que no existen fugas de información, que la validación temporal es correcta y que las métricas reportadas corresponden a datos no vistos.

Bibliografía consolidada

1. Box, G. E. P., Jenkins, G. M., Reinsel, G. C. & Ljung, G. M. (2015). *Time series analysis: forecasting and control* (5th ed.). Wiley.
2. Chen, T. & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785-794.
3. Chollet, F. (2021). *Deep learning with Python* (2nd ed.). Manning.
4. Gneiting, T. & Katzfuss, M. (2014). Probabilistic forecasting. *Annual Review of Statistics and Its Application*, 1, pp. 125-151.
5. Lazzeri, F. (2020). *Machine learning for time series forecasting with Python*. O'Reilly Media.
6. Lim, B., Arık, S. Ö., Loeff, N. & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4), pp. 1748-1764.
7. Nielsen, A. (2019). *Practical time series analysis*. O'Reilly Media.
8. Oreshkin, B. N., Carpov, D., Chapados, N. & Bengio, Y. (2020). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. *International Conference on Learning Representations*.
9. Shumway, R. H. & Stoffer, D. S. (2017). *Time series analysis and its applications: with R examples* (4th ed.). Springer.
10. Treveil, M., et al. (2020). *Introducing MLOps: practical machine learning for production*. O'Reilly Media.